



UNIVERSIDAD
POLITECNICA
DE VALENCIA

TELECOM ESCUELA
TÉCNICA **VLC** SUPERIOR
DE INGENIERÍA DE
TELECOMUNICACIÓN

Grado en Tecnología Digital y Multimedia

Diseño y desarrollo de un sistema de videollamada accesible con reconocimiento de lengua de signos española y síntesis de voz

Autor: Pablo Colomino Granell

Director: Jorge Igual Garcia

Valencia, 8 de Julio de 2026

Una brecha digital para la comunidad signante

Aunque el auge de las videollamadas ha transformado la sociedad, el colectivo de personas sordas, mudas y con limitaciones en la expresión oral continúa enfrentando un profundo aislamiento en el entorno digital. En cumplimiento con las exigencias de apoyo asistivo de la Ley 27/2007, este proyecto nace para ofrecer una respuesta interactiva a dicha brecha social.



70.000–150.000

personas signantes en España

Fuente: CNSE



Falta de adaptación

en plataformas de comunicación digital
masivas



Ley 27/2007

marco legal que exige medios de apoyo
asistivo

De la seña aislada a la conversación completa

No se buscaba solo reconocer gestos aislados, sino construir una plataforma web interactiva y completa que permitiera una interacción simétrica, fluida y bidireccional en tiempo real.




Objetivo general

Diseñar y desarrollar un sistema de videollamada accesible capaz de reconocer Lengua de Signos Española (LSE) y voz, permitiendo una comunicación bidireccional en tiempo real entre personas con cualquier limitación en la comunicación verbal o auditiva y oyentes.

Objetivos específicos


- 1 Crear un dataset propio de secuencias en LSE
- 2 Entrenar una red neuronal secuencial (BiLSTM)
- 3 Levantar un backend en Flask con WebSockets
- 4 Diseñar un frontend accesible en React
- 5 Validar la latencia y precisión

Un ecosistema orientado al procesamiento multimedia ágil




Frontend & UI

React · Vite · Tailwind CSS



Backend y Servidor

Python · Flask · Flask-SocketIO



Visión artificial e IA


MediaPipe Hands · TensorFlow



Lenguaje y audio

Ollama (Llama 3.2) · Google Cloud TTS · Web Speech API

El pipeline: de la cámara a la voz



Todo el procesamiento inteligente es estrictamente local: los píxeles se convierten de inmediato en coordenadas dactilares, optimizando el ancho de banda por WebSockets y garantizando la soberanía de los datos. Solo viaja a la nube la frase final de texto, para la síntesis de voz.

Construyendo el vocabulario desde cero

La escasez de *datasets* públicos secuenciales en LSE justificó la creación de un **dataset propio** mediante una herramienta semiautomática en Python (OpenCV), siguiendo un protocolo de ráfaga: 80 muestras de 30 frames por clase.



Herramienta de captura semiautomática (capturar.py)

Script en Python + OpenCV para grabar ráfagas etiquetadas de *landmarks* por clase, reduciendo el trabajo manual de anotación y garantizando consistencia temporal entre muestras.

Vocabulario del sistema

12	glosas comunicativas
1	clase de control — (Reposo)

La clase (*Reposo*) es una solución de ingeniería fundamental: resuelve el problema de falsos positivos cuando el usuario no está signando de manera intencionada.

Un vector simétrico y una auditoría metodológica

Vector de características (126 flotantes)

Mano izquierda 0 – 62	Mano derecha 63 – 125
---------------------------------	---------------------------------

MediaPipe extrae 21 puntos clave tridimensionales por mano.




Auditoría metodológica

Prevención de filtración de datos (data leakage)

Para garantizar el rigor científico, el conjunto de validación (20%) se separó de forma estricta antes de aplicar la aumentación de datos (ruido gaussiano y desplazamientos).

BiLSTM: capturando el contexto cinemático completo


Los signos de la LSE no son fotos estáticas: son series temporales dinámicas. Al procesar la secuencia en sentido directo (forward) e inverso (backward) de forma simultánea, la red captura la trayectoria exacta de la seña.



Bidireccionalidad = contexto pasado + futuro de cada frame, colapsando la dimensión temporal de forma robusta.

Un servidor de eventos: sesiones aisladas en tiempo real

La web tradicional (petición-respuesta) obligaría al cliente a preguntar constantemente si hay una nueva predicción. Flask-SocketIO abre un canal permanente y bidireccional entre cada dispositivo y el servidor.



Cada conexión abre su propia sesión (**sid**), con su instancia de MediaPipe y su búfer de glosas aislados. Esta base de sesiones concurrentes es el punto de partida para, en el futuro, enlazar dos sesiones mediante señalización WebRTC y transportar vídeo/audio entre dos dispositivos distintos.

De glosas sueltas a lenguaje natural

El reconocimiento de signos (SLR) devuelve una lista de glosas, sin nexos ni conjugaciones.
La gramática de la LSE difiere formalmente del español.

GLOSAS EN BRUTO (SLR)

[NOMBRE] [TÚ] [CUÁL]




ORACIÓN NATURAL (LLAMA 3.2)

¿Cuál es tu nombre?

Mediante ingeniería de prompt guiada, Llama 3.2 reestructura la frase rápidamente, de forma privada y sin depender de servidores en la nube de pago.

Discriminación perfecta en validación


La matriz de confusión del modelo BiLSTM demuestra una discriminación perfecta entre las 13 clases, gracias al aislamiento cinemático geométrico logrado por MediaPipe y a la auditoría metodológica aplicada en el preprocesado.



100% de precisión en validación



Matriz de confusión con discriminación total entre las 13 clases (12 glosas + Reposo), validada sobre un conjunto separado antes de la aumentación de datos.



Una interfaz pensada para la accesibilidad

Tracking de landmarks · modo IA · subtítulos




[Captura de la interfaz en funcionamiento]

Comunicación bidireccional simétrica



LSE → Voz: **Google Cloud TTS** sintetiza audio para que el oyente escuche.



Voz → Texto: **Web Speech API** transcribe la voz del oyente a subtítulos en pantalla.

Un producto con impacto social directo

El Grado en Tecnología Digital y Multimedia ha permitido unificar hardware, redes, IA y diseño UX en una única solución accesible y funcional.

Puntos fuertes

- ✓ Objetivos cumplidos en su totalidad
- ✓ Soberanía de datos: procesamiento local
- ✓ Escalabilidad de la arquitectura

Líneas futuras

- 👉 Mapeo holístico corporal (MediaPipe Face Mesh)
- 👉 Avatar 3D inverso para signar la voz del oyente

Gracias por su atención.